

UNIVERSIDADE DO VALE DO RIO DOS SINOS (UNISINOS)
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

MATHEUS GRASSI MILANEZI

**Sistema Inteligente de Apoio à Tomada de Decisão na Aviação Civil, baseado
em Análise de Dados e Aprendizado de Máquina para Prevenção de Acidentes**

Porto Alegre
2025

MATHEUS GRASSI MILANEZI

Sistema Inteligente de Apoio à Tomada de Decisão na Aviação Civil, baseado em Análise de Dados e Aprendizado de Máquina para Prevenção de Acidentes

Artigo será apresentado como requisito parcial para obtenção do título de Bacharel em Ciência da Computação, pelo Curso de Ciência da Computação da Universidade do Vale do Rio dos Sinos (UNISINOS).

Orientador: Prof. Ms. Dr. Rafael Kunst

Porto Alegre

2025

Sistema Inteligente de Apoio à Tomada de Decisão na Aviação Civil, baseado em Análise de Dados e Aprendizado de Máquina para Prevenção de Acidentes

Intelligent Decision Support System for Civil Aviation, based on Data Analysis and Machine Learning for Accident Prevention.

Matheus Grassi Milanezi*

Rafael Kunst**

Resumo:

Palavras-chave:

Abstract: Tradução do resumo.

Key-words: Tradução das palavras-chave.

1 INTRODUÇÃO

A aviação civil consolidou-se, ao longo das últimas décadas, como um dos meios de transporte mais seguros do mundo graças ao avanço contínuo de tecnologias, práticas de gerenciamento de risco e sistemas regulatórios rigorosos. Entretanto, a crescente complexidade das operações, influenciada por variabilidade meteorológica, pressões operacionais, diversidade de aeronaves e aumento do tráfego, impõe novos desafios à manutenção da segurança operacional. Nesse contexto, o planejamento pré-voo torna-se uma etapa importante, pois permite a identificação antecipada de condições que podem comprometer a operação e a adoção de medidas preventivas antes que tais riscos se manifestem em voo.

Ferramentas tradicionais de avaliação de risco pré-voo, como o Flight Risk Assessment Tool (FRAT), desempenham papel importante, mas apresentam limitações reconhecidas na literatura. Estudos indicam que métodos convencionais

* Graduando do curso de Bacharelado em Ciências da Computação da Universidade do Vale do Rio dos Sinos (UNISINOS). E-mail: mmilanezi@edu.unisinos.br

** Orientador Professor Ms. Dr. Rafael Kunst do curso de Ciências da Computação da Universidade do Vale do Rio dos Sinos (UNISINOS). E-mail: rafaelkunst@unisinos.br

dependem fortemente de entradas manuais, sofrem influência do viés humano e não integram automaticamente variáveis meteorológicas, históricas e operacionais. Walden et al. (2023) destacam que a estrutura atual do FRAT reduz a sensibilidade da análise em cenários dinâmicos e que modelos de Machine Learning podem modernizar essa abordagem ao fornecer uma categorização de risco mais consistente e menos subjetiva.

Paralelamente, a evolução recente da Inteligência Artificial (IA) tem demonstrado grande potencial para fortalecer os sistemas de segurança aeronáutica. Pesquisas mostram que técnicas supervisionadas podem prever eventos de segurança, antecipar condições meteorológicas adversas e apoiar decisões com maior precisão (Liu et al., 2024). Entretanto, cada estudo tende a abordar apenas um aspecto da operação sendo eles, clima, manutenção ou dados históricos, sem propor uma estrutura integrada. Zieja, Smoliński e Gołda (2015), por exemplo, enfatizam que sistemas de informação têm papel essencial na gestão da segurança, mas ainda se baseiam majoritariamente em estatística descritiva, necessitando de modelos preditivos avançados e integração em tempo real.

Além disso, discussões atuais sobre segurança operacional apontam uma mudança de paradigma do Safety-I para o Safety-II. Segundo Ziakkas e Pechlivanis (2024), a IA pode atuar como elemento central nesse novo paradigma ao permitir compreender não apenas por que operações falham, mas também por que dão certo, ampliando a resiliência do sistema e apoiando decisões em cenários complexos.

Diante desse panorama, apresenta-se uma lacuna importante: embora existam avanços em IA para previsão de eventos específicos e iniciativas isoladas de modernização do FRAT, a literatura necessita de soluções integradas que consolidem múltiplas dimensões do risco pré-voo, como meteorológica, operacional, histórica e de rota, em uma única análise automatizada. Assim, este trabalho propõe o desenvolvimento de um sistema inteligente de apoio à tomada de decisão na aviação civil capaz de estimar automaticamente o risco pré-voo combinando tais variáveis, utilizando modelos de aprendizado de máquina e alinhando-se aos princípios do Safety-II.

O estudo possui dois objetivos principais. O objetivo geral é desenvolver um sistema preditivo de apoio à decisão pré-voo que utilize múltiplas variáveis operacionais e técnicas de Inteligência Artificial para classificar automaticamente o

risco associado a uma operação aérea. No âmbito dos objetivos específicos, busca-se investigar a aplicabilidade de diferentes modelos de aprendizado de máquina como, XGBoost, Random Forest, Support Vector Machine e Redes Neurais Artificiais, na previsão do risco pré-voo, ao mesmo tempo em que se estrutura um processo integrado capaz de combinar variáveis meteorológicas, operacionais e históricas em uma única análise, reduzindo a subjetividade presente nos métodos tradicionais. Além disso, pretende-se validar o sistema por meio de simulações que evidenciem sua capacidade de apoiar decisões com maior precisão, consistência e proatividade.

Além disso, este trabalho estabelece as bases conceituais e metodológicas para a segunda etapa do projeto, a ser desenvolvida na disciplina de TCC II. Nessa fase, serão implementados e testados os modelos preditivos propostos, bem como desenvolvido o sistema inteligente de apoio à decisão, integrando os dados e técnicas aqui definidos em uma solução funcional voltada ao planejamento pré-voo.

Com isso, o trabalho busca contribuir para a evolução das práticas de segurança operacional na aviação civil, agregando ferramentas modernas de análise preditiva ao processo de planejamento pré-voo e oferecendo uma abordagem inovadora, alinhada às tendências internacionais e às necessidades regulatórias e operacionais do setor aeronáutico brasileiro.

2 FUNDAMENTAÇÃO TEÓRICA

A presente seção tem por objetivo apresentar os fundamentos teóricos que sustentam o desenvolvimento deste trabalho. Considerando que a pesquisa aborda a aplicação de Inteligência Artificial no contexto da Aviação Civil, torna-se necessário compreender, previamente, os conceitos essenciais da IA e as abordagens já propostas que buscam integrar tecnologia e segurança operacional.

2.1 História e evolução da segurança operacional na aviação civil.

A segurança operacional constitui um dos pilares centrais da aviação civil desde o surgimento do transporte aéreo comercial. Ao longo das décadas, a compreensão sobre como prevenir acidentes evoluiu profundamente, impulsionada por avanços tecnológicos, debates conceituais e pelo aumento da complexidade das

operações aéreas. Como destaca Harms (2020), a trajetória da segurança pode ser entendida pela mudança de foco entre três grandes grupos de fatores: técnicos, humanos e organizacionais/sistêmicos.

Nas primeiras décadas da aviação comercial, especialmente entre os anos 1950 e 1970, a maioria dos acidentes era atribuída a falhas técnicas, estruturais ou de projeto. Consequentemente, os esforços de segurança se concentravam quase que exclusivamente na melhoria do desempenho mecânico, na padronização de procedimentos de manutenção, na certificação de aeronaves e no fortalecimento da confiabilidade dos equipamentos. Com o amadurecimento tecnológico e a redução das falhas mecânicas, o setor identificou o erro humano como o principal fator contribuinte para acidentes, deslocando a atenção para treinamento, ergonomia, fatores cognitivos e cultura organizacional.

A partir da década de 1990, consolidou-se um novo entendimento, o acidente não é resultado de um único erro humano, mas sim o produto de falhas sucessivas dentro de um sistema complexo. Nesse período, como enfatiza Harms (2020), reconheceu-se que as condições organizacionais, pressões operacionais, limitações do ambiente e processos internos influenciavam o desempenho humano. Essa mudança marcou o início de uma transição conceitual e prática, de um modelo que em sua essência era basicamente reativo para um modelo progressivamente proativo e preditivo.

Esse movimento foi posteriormente formalizado no contraste entre Safety-I e Safety-II, conforme discute Ziakkas e Pechlivanis (2024). O Safety-I define segurança como a ausência de falhas e atua de forma reativa, investigando o que deu errado após sua ocorrência. Já o Safety-II entende segurança como a capacidade de garantir que “as coisas deem certo”, enfatizando adaptação, resiliência e antecipação de riscos. Essa visão ampliada está diretamente associada à evolução dos Sistemas de Gerenciamento da Segurança Operacional (SMS), que incorporam práticas de monitoramento contínuo, cultura de segurança, identificação precoce de ameaças e mitigação proativa.

Nesse mesmo contexto, Zieja, Smoliński e Gołda (2015) mostram que os sistemas de informação passaram a desempenhar papel fundamental nessa nova abordagem. O uso de bases de dados, métodos estatísticos e ferramentas de análise permite identificar correlações entre incidentes e acidentes, detectar tendências de falhas e compreender padrões operacionais. Com isso, a tomada de

decisão passa a ser baseada em evidências e indicadores, reduzindo a margem de erro humano e fortalecendo a gestão de risco antes que ameaças se materializem.

Paralelamente, o setor enfrenta hoje um cenário controverso, onde a aviação atingiu níveis tão elevados de segurança que se torna cada vez mais difícil medir melhorias ou identificar indícios iniciais de eventos adversos, justamente porque acidentes são raros. Como observa Harms (2020), a ausência de ocorrências relevantes desafia os métodos tradicionais de vigilância e exige novas formas de análise capazes de revelar riscos ocultos.

Diante dessa realidade, o avanço para um modelo plenamente proativo e preditivo aponta naturalmente para o uso de técnicas de Inteligência Artificial (IA) e aprendizado de máquina. Esses sistemas oferecem a capacidade de processar grandes volumes de dados, identificar padrões não perceptíveis ao analista humano e antecipar condições que possam levar a um acidente. Assim, configuram-se como a próxima etapa da evolução da segurança operacional na aviação comercial, alinhada ao paradigma Safety-II e às exigências de um setor cada vez mais complexo, dinâmico e orientado por dados.

2.2 Avaliação de risco e o conceito de análise pré-voo

A avaliação de risco pré-voo constitui uma das etapas mais relevantes do gerenciamento da segurança operacional, pois permite identificar perigos, avaliar a exposição ao risco e adotar medidas de mitigação antes da decolagem. Ferramentas como o Flight Risk Assessment Tool (FRAT) foram desenvolvidas para estruturar esse processo, mensurando o nível de risco associado a uma operação aérea antes que ela ocorra. Esses instrumentos utilizam questionários e pontuações baseadas em fatores como condições meteorológicas, experiência e proficiência do piloto, características da aeronave, manutenção, familiaridade com o aeródromo e perfil da missão.

Como apresentado por Walden et al. (2023), durante o planejamento pré-voo o piloto deve considerar múltiplos elementos antes de decidir se irá voar, ele deverá analisar utilizando ferramentas como o FRAT. Essa análise sistemática também é reforçada por checklists como o PAVE, acrônimo de Pilot, Aircraft, enVironment e External Pressures, que orienta o piloto a avaliar os principais itens de risco.

Apesar de amplamente utilizados, estudos recentes apontam limitações no FRAT tradicional. Essas ferramentas dependem de entradas manuais e da interpretação subjetiva do operador, o que pode gerar inconsistências, vieses cognitivos e subestimação de riscos (WALDEN et al., 2023). Além disso, os modelos atuais não integram dados históricos de acidentes, relatórios de incidentes ou análises automatizadas, reduzindo sua precisão e abrangência. Walden et al. (2023) destacam que muitos FRATs apresentam baixa acessibilidade, questionários incompletos, elevado tempo de preenchimento e ausência de requisitos regulatórios que incentivem seu uso contínuo. Também não incorporam a probabilidade de ocorrência dos perigos e, conseqüentemente, não fornecem uma estimativa quantitativa robusta do risco.

Buscando superar essas limitações, Walden et al. (2023) propõem a modernização do FRAT por meio do uso de técnicas de aprendizado de máquina, como XGBoost, Random Forest, redes neurais e modelos baseados em BERT, treinadas com bases históricas, como os registros do National Transportation Safety Board (NTSB). Segundo os autores, esses modelos são capazes de prever categorias de risco com base no perfil de voo e em padrões presentes em décadas de acidentes e incidentes, reduzindo o viés humano e permitindo uma avaliação mais consistente e preditiva.

Em linha com essa evolução, Feldman et al. (2023) descrevem soluções de análise pré-voo utilizadas pelo In-Time Aviation Safety Management System (IASMS) da NASA, que reúne dados de sistemas aeronáuticos e fontes ambientais para prever perigos e apresentar informações preditivas aos operadores durante o planejamento. Esses sistemas demonstram que a integração de dashboards de risco com análise automatizada aumenta a consciência situacional e oferece suporte à tomada de decisão, especialmente quando envolvem múltiplas aeronaves, rotas complexas ou cenários meteorológicos dinâmicos.

Outro aspecto crítico da avaliação pré-voo diz respeito à meteorologia. Liu et al. (2024) ressaltam que o crescimento do transporte aéreo intensifica a necessidade de suporte meteorológico de alta precisão, uma vez que fenômenos perigosos, como turbulência severa, mudanças bruscas de direção do vento chamadas de windshear, tempestades convectivas e baixa visibilidade impactam diretamente a segurança operacional. Para os autores, a melhoria da capacidade de alerta antecipado de tempo severo é uma das principais funções dos serviços de meteorologia

aeronáutica. Modelos de aprendizado de máquina, como SVMs treinados com dados de estações meteorológicas, têm demonstrado elevada capacidade de prever condições adversas e antecipar situações em que o clima pode decidir entre um voo seguro e um acidente.

Essa compreensão reforça um ponto amplamente discutido na literatura de segurança operacional: muitos acidentes têm origem ainda na fase de preparação. De acordo com Wright (2019, apud WALDEN et al., 2023), falhas de gestão de risco foram causa raiz de quase 50% dos acidentes fatais com aeronaves de negócios, e a maioria poderia ser rastreada a deficiências no planejamento pré-voo.

Assim, a análise pré-voo emerge como uma fase determinante para interromper precursões de risco antes que avancem no sistema e evoluam para um incidente ou acidente. A incorporação de inteligência artificial e modelos preditivos, nesse sentido, representa uma resposta direta às limitações dos métodos tradicionais de avaliação de risco e às evidências históricas mostram que decisões tomadas no solo são frequentemente o ponto em que a segurança do voo é definida.

2.3 A Importância dos dados de voo e relatórios de incidentes

Os dados de voo, os registros de manutenção e os relatórios de incidentes constituem a base da gestão moderna da segurança operacional. A capacidade de analisar grandes volumes de informações referentes às operações aéreas tornou-se importante para compreender o comportamento do sistema e identificar vulnerabilidades antes que elas evoluam para eventos mais graves. Nesse sentido, Demir, Moslem e Duleba (2024) destacam que a análise sistemática de conjuntos massivos de dados permite identificar padrões de risco, detectar anomalias operacionais e aprimorar a capacidade preditiva dos modelos de segurança.

Essa perspectiva é reforçada por Zieja, Smoliński e Gołda (2015), que destacam o papel dos sistemas de informação na identificação de relações entre variáveis críticas, como falhas técnicas, fatores humanos e condições operacionais. Segundo os autores, a análise de segurança tem como ponto de partida dados históricos de eventos de voo e indicadores operacionais, os quais permitem compreender padrões recorrentes e orientar decisões mais precisas. Essa abordagem estatística também revela regularidades e possíveis relações causais, ajudando a responder questões fundamentais como: que problema está sendo

enfrentado? quais são suas causas raízes? e quais fatores influenciam com maior probabilidade a ocorrência de fenômenos perigosos?

O uso contínuo desses registros não apenas sustenta avaliações de desempenho e auditorias de segurança, mas também possibilita o desenvolvimento de relatórios estatísticos e indicadores que medem a eficácia de programas de treinamento e ações mitigadoras, e de sistemas de prevenção de acidentes aéreos. Assim, dados bem estruturados permitem uma avaliação proativa e fundamentada do desempenho operacional, facilitando decisões que minimizam erros e aumentam a confiabilidade das operações aéreas.

A literatura também evidencia que a qualidade e a quantidade desses dados têm impacto direto na eficácia dos sistemas de segurança. Conforme afirmam Demir, Moslem e Duleba (2024), modelos baseados em inteligência artificial dependem de dados históricos de voo, registros de manutenção e relatórios de incidentes para aprender continuamente com as ocorrências operacionais e produzir previsões confiáveis. Da mesma forma, Harms (2020) enfatiza que a segurança na aviação está cada vez mais associada à análise de dados, uma vez que a avaliação do desempenho de segurança de uma companhia aérea é, em grande parte, fundamentada na capacidade de interpretar adequadamente seus registros operacionais.

Nesse contexto, os dados tornam-se não apenas insumos técnicos, mas elementos estruturantes da segurança operacional. Sem bases de dados consistentes, extensas e confiáveis, não há como desenvolver modelos preditivos robustos, identificar precursores de risco ou sustentar práticas proativas alinhadas ao paradigma Safety-II. Dessa forma, a gestão de dados emerge como componente essencial para qualquer iniciativa de inteligência artificial aplicada à segurança de voo, incluindo ferramentas de análise pré-voo como a proposta neste trabalho.

2.4 Inteligência artificial e aprendizado de máquina aplicados à segurança aeronáutica

A Inteligência Artificial (IA) e o Aprendizado de Máquina (Machine Learning – ML) têm desempenhado um papel cada vez mais relevante na segurança aeronáutica, especialmente em um cenário onde a complexidade das operações aéreas, a quantidade de dados gerados e a necessidade por decisões rápidas e

precisas desafiam os métodos tradicionais de análise. A aviação moderna tornou-se um terreno fértil para soluções baseadas em dados, pois combina um sistema de altíssimo nível de segurança com uma infraestrutura de registro detalhado de eventos, falhas, condições meteorológicas e parâmetros operacionais. Esse ambiente fornece o que algoritmos de IA mais precisam: grandes volumes de dados estruturados, contínuos e historicamente ricos.

Segundo Demir, Moslem e Duleba (2024), o uso crescente de IA reflete um movimento global em direção a sistemas preditivos capazes de identificar riscos antes que se materializem. Os autores mostram que a análise de grandes conjuntos de dados aeronáuticos permite capturar padrões ocultos, detectar anomalias, prever condições adversas e auxiliar na tomada de decisão em tempo real. Já Harms (2020) destaca que a segurança na aviação está cada vez mais associada à análise automatizada de dados, afirmando o quão importante é na avaliação do desempenho de segurança operacional.

Esses avanços seguem a mesma lógica do paradigma Safety-II, conforme apresentado por Ziakkas e Pechlivanis (2024), que propõe uma visão proativa da segurança operacional, centrada em compreender como as operações dão certo e como reforçar a resiliência do sistema. Assim, a IA surge não apenas como uma ferramenta tecnológica, mas como uma evolução natural das práticas de segurança aeronáutica.

2.4.1 Fundamentos de Inteligência Artificial e Aprendizado de Máquina no Contexto da Aviação

A Inteligência Artificial (IA) refere-se ao desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiriam raciocínio humano, como classificação, previsão e tomada de decisão. Segundo Kühn et al. (2022), uma das dificuldades recorrentes no uso do termo é que ele é frequentemente confundido com aprendizado de máquina, embora IA seja um conceito mais amplo que engloba múltiplas abordagens para criar agentes capazes de perceber e agir em um ambiente de forma racional.

Dentro desse campo, o Aprendizado de Máquina (Machine Learning – ML) representa o conjunto de métodos que permitem que modelos aprendam padrões automaticamente a partir dos dados, sem que todas as regras sejam explicitamente

programadas. Kühl et al. (2022) explicam que modelos de ML podem resolver problemas reais ao “aprender” relações internas nos dados e ajustar seu comportamento com base nessa experiência, em vez de dependerem apenas de instruções pré-programadas.

No contexto da aviação, o ML encontra aplicações naturais em tarefas que envolvem uma grande quantidade de dados históricos, variáveis fortemente correlacionadas, necessidade de previsões rápidas e risco elevado associado ao erro humano.

Essas características fazem da aviação um ambiente ideal para modelos que aprendem a partir do comportamento passado e conseguem estimar, com antecedência, condições potencialmente perigosas.

O treino desses modelos consiste em fornecer exemplos históricos e permitir que os algoritmos aprendam relações matemáticas entre variáveis, representando o comportamento do sistema em cenários reais. Entre as categorias existentes, aquela que mais se destaca nas aplicações aeronáuticas é o aprendizado supervisionado, no qual os dados possuem rótulos conhecidos. Conforme ressaltam Kühl et al. (2022), esse tipo de aprendizado busca criar um modelo capaz de generalizar a partir de exemplos rotulados.

Na prática da aviação, esse paradigma é amplamente utilizado para lidar com problemas como, identificar se um voo representa “risco baixo”, “médio” ou “alto”, prever se uma aproximação será “estável” ou “instável”, classificar condições meteorológicas como “seguras” ou “perigosas”, prever ocorrência ou não de eventos de segurança.

Essas aplicações encaixam-se diretamente no modelo supervisionado porque envolvem padrões já observados (eventos passados) e rotulagem operacional compatível (eventos de risco já registrados).

2.4.2 Modelos de Aprendizado de Máquina Utilizados na Segurança Aeronáutica

A literatura sobre segurança aeronáutica demonstra que diferentes modelos de Aprendizado de Máquina têm sido utilizados para analisar dados operacionais, prever eventos de risco e apoiar decisões críticas na aviação. Embora haja um amplo conjunto de algoritmos disponíveis, alguns métodos se destacam por sua

capacidade de lidar com bases de dados tabulares, variáveis altamente correlacionadas, cenários complexos e, principalmente, pela robustez necessária em sistemas de segurança. Nesse contexto, modelos baseados em técnicas de ensemble, máquinas de vetores de suporte e redes neurais artificiais aparecem de forma recorrente nas pesquisas analisadas.

O modelo Random Forest surge como uma das técnicas mais utilizadas em estudos de segurança de voo. Ele combina diversas árvores independentes, treinadas sobre subconjuntos aleatórios dos dados, de modo que a predição final resulta da agregação das decisões individuais. Esse mecanismo reduz a variabilidade do modelo, minimiza overfitting e oferece excelente desempenho com dados heterogêneos e ruidosos. Pois, dados deste tipo são condições típicas de registros operacionais aeronáuticos. Por essas razões, Random Forest aparece com destaque em trabalhos como Walden et al. (2023) e é citado como uma solução relevante também na revisão sistemática de Demir, Moslem e Duleba (2024).

Outro modelo central na literatura analisada é o XGBoost (Extreme Gradient Boosting), um dos algoritmos mais eficazes para dados tabulares estruturados. O XGBoost constrói sequências de árvores onde cada nova árvore busca corrigir erros das anteriores por meio da otimização de gradiente, alcançando alto desempenho mesmo em conjuntos de dados desbalanceados. Sua capacidade de capturar interações complexas entre variáveis, aliada à relativa interpretabilidade dos seus parâmetros, fez com que este modelo fosse adotado no estudo de Walden et al. (2023) para modernizar o processo de avaliação de risco pré-voo. No contexto deste trabalho, ele se destaca como um dos principais candidatos a integrar o sistema proposto.

Para o tratamento de dados meteorológicos, que possuem comportamento contínuo, alta variabilidade e forte correlação interna, outro modelo que se destaca é o Support Vector Machine (SVM). O SVM trabalha identificando o hiperplano com maior margem de separação entre classes, o que o torna especialmente eficiente na categorização de condições atmosféricas complexas. Liu et al. (2024) aplicou o método com sucesso para prever fenômenos que impactam a segurança de voo, demonstrando sua capacidade de antecipar condições adversas com alta precisão. Assim, o SVM torna-se particularmente valioso sempre que a análise envolve múltiplas variáveis climáticas, como vento, temperatura, pressão atmosférica ou umidade.

Além desses modelos, as Redes Neurais Artificiais (ANN) representam outra abordagem amplamente empregada em contextos onde a complexidade dos padrões exige maior capacidade de generalização. Estruturadas em camadas de neurônios artificiais interconectados que aplicam funções não lineares às entradas, as ANNs conseguem capturar relacionamentos sutis e frequentemente não lineares entre as variáveis. Na aviação, Harms (2020) utilizou redes neurais para prever eventos de aproximação instável, demonstrando que esses modelos são eficazes para identificar padrões complexos associados a eventos de risco.

De forma complementar, técnicas de Processamento de Linguagem Natural (NLP) e modelos de linguagem, como o BERT, também aparecem na literatura, especialmente em análises que envolvem relatórios narrativos de incidentes. Walden et al. (2023), por exemplo, aplicaram BERT para extrair informações semânticas de textos não estruturados, permitindo identificar expressões e termos associados a situações de risco. Embora tais modelos não sejam necessariamente centrais para todos os sistemas, eles ampliam a capacidade de incorporar fontes de dados textuais, fortalecendo a abordagem de gestão de segurança orientada a dados.

A partir do conjunto de evidências analisado, percebe-se que a escolha dos modelos deve considerar tanto as características dos dados disponíveis quanto os objetivos específicos da análise. Nesse sentido, e alinhado ao propósito deste trabalho, os modelos que se mostram mais adequados ao desenvolvimento de um sistema inteligente de apoio à decisão pré-voo são aqueles capazes de lidar com dados tabulares complexos, prever categorias de risco e operar com robustez em cenários de variáveis heterogêneas. Assim, com base na literatura, o sistema proposto neste trabalho adotará XGBoost, Random Forest e Support Vector Machines como modelos preditivos principais, dada sua adequação às tarefas de previsão de risco pré-voo.

2.4.3 Aplicações da IA na Segurança Aeronáutica e Limitações Identificadas pela Literatura

A literatura recente revela que a Inteligência Artificial tem desempenhado papéis diversos e complementares na segurança aeronáutica, envolvendo desde a previsão de eventos operacionais até o suporte ao processo decisório pré-voo. Cada

estudo analisado contribui para compreender como diferentes técnicas de Aprendizado de Máquina podem ser aplicadas a aspectos específicos das operações aéreas, mas também evidencia limitações estruturais que ainda impedem a formação de sistemas verdadeiramente integrados e abrangentes.

No âmbito da análise de dados de voo e identificação de precursores, Harms (2020) demonstra que técnicas supervisionadas, incluindo redes neurais, são capazes de prever eventos de segurança com base em variáveis indiretas e em padrões complexos presentes nos dados operacionais. O autor também destaca que a eficácia desses modelos depende fortemente da disponibilidade e qualidade dos dados históricos, especialmente porque eventos negativos são raros e dificultam o treinamento de modelos supervisionados robustos. Esse aspecto evidencia um dos principais desafios da área: a escassez de ocorrências críticas em bases de dados suficientemente extensas.

No campo da avaliação pré-voo, Walden et al. (2023) evidenciam que modelos como XGBoost, Random Forest, redes neurais e BERT melhoram a consistência e precisão do processo, superando limitações do FRAT tradicional. Ainda assim, os autores observam que ferramentas atuais geralmente não integram dados meteorológicos, operacionais e históricos de maneira conjunta, restringindo a abrangência da análise.

Em relação às condições meteorológicas, Liu et al. (2024) mostra que o Support Vector Machine apresenta alta precisão para prever fenômenos climáticos adversos. Contudo, seu desempenho pode ser limitado por ruído nos dados e pela variabilidade regional, indicando que previsões meteorológicas isoladas não são suficientes para avaliações mais completas de risco.

A revisão sistemática de Demir, Moslem e Duleba (2024) reforça esse cenário ao apontar que grande parte das pesquisas aplica IA a fatores isolados da operação aérea, seja clima, manutenção ou dados de voo, mas sem propor um modelo unificado. Zieja, Smoliński e Gołda (2015) complementam essa visão ao ressaltar a importância dos sistemas de informação para correlacionar incidentes, falhas técnicas e fatores humanos, mas destacam desafios relativos à padronização e integração de dados.

Por fim, pesquisas como a de Feldman et al. (2023) mostram que sistemas inteligentes podem apresentar riscos em tempo real durante o planejamento pré-voo, enquanto Ziakkas e Pechlivanis (2024) situam a IA como elemento essencial do

paradigma Safety-II. No entanto, ambos reforçam que a eficácia desses sistemas depende da integração de informações diversas e de interfaces claras, algo que ainda não é plenamente realizado nas ferramentas disponíveis.

Embora a IA já tenha avançado em áreas específicas, como previsão meteorológica, avaliação pré-voo e detecção de eventos de segurança, a literatura indica que as soluções existentes permanecem segmentadas e apresentam limitações quanto à integração de dados, cobertura operacional e capacidade de generalização. Esses elementos mostram a principal lacuna a ser enfrentada e fundamentam a necessidade de sistemas mais abrangentes. Nesse contexto, insere-se a proposta deste trabalho: desenvolver um sistema inteligente capaz de integrar variáveis diversas, como clima, características da aeronave, histórico operacional e condições da rota, utilizando modelos de aprendizado de máquina para estimar o risco pré-voo de forma automatizada, consistente e orientada à tomada de decisão.

3 SOLUÇÃO PROPOSTA

A solução proposta neste trabalho consiste no desenvolvimento de um sistema inteligente de apoio à tomada de decisão pré-voo, pensado para avaliar automaticamente o risco associado a uma operação aérea com base na integração de variáveis meteorológicas, características da aeronave, informações de rota e histórico operacional. A proposta surge diretamente da lacuna identificada na literatura, que demonstra avanços isolados em previsão meteorológica, detecção de eventos de segurança e avaliação de risco, mas destaca a ausência de uma ferramenta capaz de unificar múltiplas fontes de dados em um processo único, coerente e realmente representativo da complexidade operacional da aviação civil. Assim, o sistema aqui proposto busca superar essa fragmentação ao estruturar uma arquitetura capaz de reunir, tratar e analisar informações diversas, fornecendo ao operador um diagnóstico que apoia decisões críticas antes da decolagem.

O sistema inicia pela recepção das informações essenciais ao planejamento pré-voo, como dados meteorológicos atuais e previstos, parâmetros operacionais da aeronave, estado de manutenção, condições da rota e registros históricos relevantes. Esses dados são integrados em um módulo central que organiza e harmoniza todas as variáveis, permitindo que diferentes tipos de informação (numéricas, categóricas e contextuais) sejam analisadas de maneira conjunta. Essa

integração é um elemento central da proposta, pois possibilita que o diagnóstico de risco reflita simultaneamente múltiplos fatores que, na prática, influenciam a segurança do voo de forma combinada, e não isolada, como apontado pela literatura.

O núcleo analítico do sistema é composto por quatro modelos de aprendizado de máquina selecionados com base na revisão teórica e na adequação às características dos dados aeronáuticos: XGBoost, Random Forest, Support Vector Machine (SVM) e Redes Neurais Artificiais (ANN). Cada modelo desempenha um papel complementar dentro da solução. O XGBoost se destaca pela capacidade de lidar com grande número de variáveis e por sua elevada precisão em bases tabulares com interações complexas, características típicas de cenários de risco pré-voo. O Random Forest contribui com robustez e estabilidade em dados heterogêneos, reduzindo overfitting e oferecendo boa interpretabilidade operacional. O SVM é empregado principalmente nas variáveis de natureza meteorológica, pois apresenta excelente desempenho na separação de padrões climáticos potencialmente perigosos. Já as Redes Neurais se mostram adequadas para captar relações não lineares e precursores indiretos que não são facilmente representados por métodos baseados em árvores ou separadores lineares. Ao combinar esses modelos, o sistema se beneficia de abordagens distintas e complementares, criando uma estrutura analítica mais abrangente e sensível às múltiplas dimensões do risco aeronáutico.

Após o processamento pelos modelos, o sistema reúne os resultados preditivos e gera uma classificação automática de risco pré-voo, que pode ser representada em categorias como “Apto”, “Moderado” ou “Não Apto”. Essa classificação final é derivada da integração das informações fornecidas pelos modelos e do conjunto de variáveis analisadas, refletindo a condição global da operação. O diagnóstico é então apresentado ao usuário sejam, piloto, despachante operacional ou gestor de segurança de maneira clara, direta e interpretável, permitindo rápida assimilação e facilitando a tomada de decisão. A solução, portanto, não substitui o julgamento humano, mas o complementa ao reduzir subjetividades, consolidar informações dispersas e antecipar riscos que poderiam passar despercebidos em avaliações manuais.

Com essa arquitetura, o sistema proposto não apenas aponta as limitações observadas na literatura, mas introduz uma solução inovadora que aproxima a

avaliação de risco pré-voo de uma abordagem sistêmica, abrangente e tecnologicamente atualizada. Dessa forma, o modelo proposto se posiciona como uma contribuição concreta à evolução das práticas de segurança na aviação civil, oferecendo uma ferramenta capaz de apoiar decisões críticas com maior precisão, consistência e respaldo analítico.

4 METODOLOGIA

A metodologia adotada neste estudo será estruturada para desenvolver e validar um sistema inteligente de apoio à tomada de decisão pré-voo capaz de estimar automaticamente o risco operacional de uma aeronave. Trata-se de uma pesquisa aplicada, com abordagem quantitativa, por utilizar dados estruturados, métricas numéricas e experimentação computacional. Seu caráter também é exploratório e descritivo, ao investigar as possibilidades da Inteligência Artificial na segurança de voo, e experimental, por envolver o desenvolvimento e teste de um protótipo funcional.

A construção do sistema baseará em dados históricos, simulados e adaptados de fontes consolidadas. Serão utilizados registros públicos nacionais, como dados do Instituto Nacional de Meteorologia (INMET), além de diretrizes e normativas emitidas pela Agência Nacional de Aviação Civil (ANAC), autoridade responsável pela regulamentação do setor no Brasil. As orientações da agência, especialmente no que se refere ao Gerenciamento da Segurança Operacional (SGSO) e aos requisitos aplicáveis à avaliação de risco, servirão como referência para a definição das categorias e parâmetros considerados no sistema. Para suprir lacunas e ampliar a diversidade de cenários, dados simulados serão adicionados, garantindo representatividade para condições críticas, rotas específicas, variações climáticas e diferentes perfis de aeronaves. O conjunto final incluirá variáveis relacionadas a clima, rota, tipo de aeronave, histórico operacional, estado de manutenção e categoria de risco associada ao evento.

O núcleo analítico do estudo constituirá na modelagem preditiva com quatro algoritmos selecionados: Random Forest, XGBoost, Support Vector Machine (SVM) e Redes Neurais Artificiais (ANN). Esses modelos foram escolhidos devido à sua relevância na literatura e adequação ao tipo de dados utilizado.

Os módulos do sistema serão integrados de forma a permitir que os dados de entrada sejam processados pelos modelos preditivos e resultem em uma classificação automática do risco pré-voo, categorizada em níveis como “Apto”, “Moderado” ou “Não Apto”. O desenvolvimento será realizado em Python, utilizando bibliotecas como Pandas, NumPy, Scikit-learn e TensorFlow, com apoio de ferramentas de prototipagem para visualização e interface.

A validação do sistema ocorrerá por meio de simulações que envolveram diferentes cenários operacionais, especialmente condições meteorológicas adversas, falhas de manutenção e rotas críticas.

5 CONSIDERAÇÕES FINAIS

REFERÊNCIAS

AGÊNCIA NACIONAL DE AVIAÇÃO CIVIL (ANAC). Regulamentos, boletins e dados estatísticos de segurança operacional. Brasília, 2024. Disponível em: <https://www.gov.br/anac>. Acesso em: 21 nov. 2025.

DEMIR, Gülay; MOSLEM, Sarbast; DULEBA, Szabolcs. Artificial Intelligence in Aviation Safety: Systematic Review and Biometric Analysis. **Future Transportation**, 2024. Disponível em: <https://link.springer.com/article/10.1007/s44196-024-00671-w>. Acesso em: 21 set. 2025.

FELDMAN, Jolene; MARTIN, Lynne; COSTEDOAT, Gregory; GUJRAL, Vimmy. Usability of Pre-Flight Planning Interfaces for Supplemental Data Service Provider Tools to Support Uncrewed Aircraft System Traffic Management. **Application of Emerging Technologies**, v. 115, p. 357–366, 2023. Disponível em: <https://doi.org/10.54941/ahfe1004333>. Acesso em: 21 set. 2025.

HARMS, T. A Machine Learning Approach to Flight Safety Event Prediction. **Delft University of Technology**, 2020. Disponível em: https://repository.tudelft.nl/file/File_07171b32-693a-4589-b0aa-226c6608898e?preview=1. Acesso em: 25 fev. 2025.

INSTITUTO NACIONAL DE METEOROLOGIA (INMET). Dados meteorológicos e boletins climáticos. Brasília, 2024. Disponível em: <https://portal.inmet.gov.br>. Acesso em: 21 nov. 2025.

KÜHL, Niklas; SCHEMMER, Max; GOUTIER, Marc; SATZGER, Gerhard. Artificial Intelligence and Machine Learning: Untangling Concepts and Terminology for AI-Based Information Systems. **Electronic Markets**, 2022. Disponível em: <https://link.springer.com/content/pdf/10.1007/s12525-022-00598-0.pdf>. Acesso em: 21 nov. 2025.

LIU, Haoxing; XIE, Renjie; QIN, Haoshen; LI, Yizhou. Research on Dangerous Flight Weather Prediction Based on Machine Learning. **Journal of Physics: Conference Series**, v. 2870, n. 1, 2024. Disponível em: <https://iopscience.iop.org/article/10.1088/1742-6596/2870/1/012020/meta>. Acesso em: 18 set. 2025.

WALDEN, Hunter; HILL, Kathleen; QUINN, Chi; TORRES, Erick; GANG, Isaac. Proposal for a Modernized Flight Risk Assessment Tool for General Aviation Pre-Flight Planning. 2023. Disponível em: https://faadatachallenge.nianet.org/wp-content/uploads/T1_GMU_Gang.pdf. Acesso em: 18 set. 2025.

ZIAKKAS, Dimitrios; PECHLIVANIS, Konstantinos. The Role of Artificial Intelligence in Transportation Safety Management Systems: The Aviation Safety II Case Study. **Safety Management and Human Factors**, 2024. Disponível em: https://openaccess.cms-conferences.org/publications/book/978-1-964867-27-4/article/978-1-964867-27-4_0. Acesso em: 18 set. 2025.

ZIEJA, Mariusz; SMOLIŃSKI, Henryk; GOŁDA, Paweł. Information Systems as a Tool for Supporting the Management of Aircraft Flight Safety. 2015. Disponível em: <https://archivesoftransport.com/index.php/aot/article/view/117>. Acesso em: 18 set. 2025.

APÊNDICE A – TÍTULO DO APÊNDICE

ANEXO A – TÍTULO DO ANEXO